

Rendimiento del Ensemble de Vision Transformers (ViT) en la Detección de Out-of-Distribution (OOD) en CIFAR-100: Análisis de un AUROC del 98.11%

Resumen

Este informe investiga el rendimiento excepcional de los ensembles de Vision Transformers (ViT) en la detección de Out-of-Distribution (OOD), centrándose específicamente en el logro de un AUROC (Área bajo la curva ROC) del 98.11% en el desafiante benchmark CIFAR-100 vs. CIFAR-10. Se profundiza en las ventajas arquitectónicas de los ViTs, los beneficios sinérgicos del aprendizaje por ensemble y la eficacia de varios métodos de puntuación OOD, en particular la distancia de Mahalanobis, que fue fundamental para alcanzar este resultado de vanguardia. Aunque la metodología exacta del ensemble para este logro específico no se detalla en la fuente principal, se contextualiza este rendimiento con respecto a benchmarks anteriores y se discuten tendencias más amplias en la detección OOD basada en ViT, incluyendo avances recientes y desafíos persistentes. El informe destaca el papel crítico del pre-entrenamiento a gran escala, la aumentación de datos y el ajuste fino estratégico para aprovechar los ViTs en la construcción de sistemas de IA robustos para aplicaciones críticas para la seguridad.

1. Introducción a la Detección de Out-of-Distribution y Vision Transformers

La Importancia Crítica de la Detección OOD en Aplicaciones de IA en el Mundo Real

Las redes neuronales profundas, a pesar de su alto rendimiento en datos dentro de la distribución (ID), tienden a realizar predicciones excesivamente confiadas e incorrectas cuando se enfrentan a muestras fuera de la distribución (OOD). Esto presenta riesgos significativos en dominios críticos para la seguridad, como la conducción autónoma, el diagnóstico médico, la detección de seguridad y los sistemas financieros, donde los resultados poco fiables pueden tener graves consecuencias.

La detección OOD es la tarea de identificar si una muestra de entrada difiere significativamente de la distribución de entrenamiento. Es fundamental para permitir que los sistemas de aprendizaje automático señalen entradas anómalas, inicien políticas de respaldo conservadoras o deleguen la decisión al juicio humano. La reiterada mención de "aplicaciones críticas para la seguridad" en la literatura subraya que la detección de OOD trasciende la mera investigación académica. Se ha convertido en un requisito fundamental para el despliegue responsable y ético de sistemas de inteligencia artificial. Esta tendencia indica un cambio en el enfoque de la investigación, que pasa de la optimización de la precisión pura a la priorización de la robustez y la fiabilidad en escenarios del mundo real y abiertos, donde la aparición de datos no vistos es inevitable. La capacidad de un sistema

de IA para identificar y gestionar datos fuera de su distribución de entrenamiento es, por tanto, un pilar esencial para garantizar su confianza y seguridad operativa.

Visión General de los Vision Transformers (ViTs) y sus Principios Fundamentales

Los ViTs representan un cambio de paradigma con respecto a las Redes Neuronales Convolucionales (CNNs) tradicionales, al aplicar arquitecturas de transformadores, originalmente diseñadas para tareas de Procesamiento de Lenguaje Natural (PLN), a datos de imagen. Operan sobre secuencias de parches de imagen, capturando dependencias de largo alcance y contexto global a través de mecanismos de autoatención.

A diferencia de las CNNs, los ViTs poseen un sesgo inductivo más débil, lo que generalmente se traduce en una mayor dependencia de grandes volúmenes de datos de entrenamiento o de esquemas robustos de aumentación y regularización de datos (AugReg) para evitar el sobreajuste, especialmente en conjuntos de datos más pequeños. La característica de un "sesgo inductivo más débil" en los ViTs, aunque inicialmente se percibió como una limitación que exigía vastos conjuntos de datos, es simultáneamente una fortaleza para la detección OOD. Al no estar intrínsecamente sesgados hacia características locales como las CNNs, los ViTs pueden aprender representaciones más globales y abstractas. Esta comprensión holística resulta crucial para distinguir datos novedosos y no vistos de las distribuciones conocidas. Este contraste con las CNNs, que podrían sobreajustarse a texturas locales y tener dificultades con composiciones globales novedosas, sugiere una ventaja arquitectónica fundamental para las tareas OOD.

Introducción al Aprendizaje por Ensemble como Estrategia para la Robustez del Modelo

Los métodos de ensemble combinan las predicciones de múltiples modelos base para mejorar la precisión y fiabilidad general, particularmente en tareas como la detección OOD y la estimación de la incertidumbre. La hipótesis central es que los modelos diversos, entrenados bajo los mismos o diferentes criterios, pueden proporcionar colectivamente una evaluación más robusta y precisa de la incertidumbre y la probabilidad OOD que un solo modelo. Los ensembles profundos, en particular, son conocidos por generar advertencias a través de una mayor incertidumbre cuando se enfrentan a datos desplazados o OOD, facilitando la intervención humana.

Definición de la Tarea de Detección OOD en CIFAR-100

La tarea implica distinguir entre imágenes del conjunto de datos CIFAR-100 (dentro de la distribución, ID) e imágenes del conjunto de datos CIFAR-10 (fuera de la distribución, OOD). Este emparejamiento específico (CIFAR-100 vs. CIFAR-10) se considera una tarea "casi OOD", lo que la hace significativamente más desafiante que las tareas "lejos OOD"

(por ejemplo, CIFAR-100 vs. SVHN o Texturas) porque las clases son semánticamente similares (por ejemplo, "autobús" vs. "automóvil"). El AUROC (Área bajo la curva ROC) es una métrica independiente del umbral comúnmente utilizada para evaluar el rendimiento general de OOD, tratando el conjunto de prueba OOD como el conjunto positivo y el conjunto de prueba dentro de la distribución como el conjunto negativo.

2. Vision Transformers como Extractores de Características para la Detección OOD

Capacidades Inherentes de ViT para Capturar el Contexto Global y las Dependencias de Largo Alcance

Los ViTs sobresalen en la captura de dependencias de largo alcance y representaciones globales dentro de las imágenes, proporcionando una interpretación más completa de escenas complejas en comparación con las CNNs, que son espacialmente locales. Esta capacidad de sintetizar información contextual extensa más allá del mero análisis de píxeles es una ventaja clave para la detección OOD. El mecanismo de autoatención permite a los ViTs comprender las relaciones entre los parches de imagen, contribuyendo a sus potentes capacidades de extracción de características. La fortaleza de los ViTs en la captura de contexto global y dependencias de largo alcance se traduce directamente en un rendimiento mejorado en la detección OOD, ya que las muestras OOD a menudo se manifiestan como desviaciones en la estructura semántica global, no solo como anomalías de píxeles locales. Un modelo que comprende la "imagen completa" está mejor equipado para identificar cuándo esa imagen es fundamentalmente "incorrecta" o "no vista". Por ejemplo, si una imagen OOD tiene características locales que se asemejan a datos ID (como un coche en un contexto nuevo o un animal novedoso con pelo y ojos), una CNN podría ser engañada. Sin embargo, un ViT, al analizar la disposición *global* de los parches y sus interdependencias, puede detectar que la composición general o la estructura semántica no se alinea con ninguna clase ID conocida. Esto podría llevar a una puntuación OOD más alta, sugiriendo que los ViTs son más aptos para detectar cambios OOD a nivel de "concepto" que solo a nivel de "característica".

Impacto de la Escala de Pre-entrenamiento y la Aumentación de Datos en el Rendimiento de ViT

Los ViTs dependen en gran medida del pre-entrenamiento a gran escala, ya sea a través de aprendizaje supervisado (por ejemplo, ImageNet-21k, JFT-300M) o aprendizaje auto-supervisado, para lograr resultados de vanguardia. Los transformadores pre-entrenados, especialmente los de ImageNet-21k, mejoran significativamente la detección OOD.

La aumentación y regularización de datos (AugReg) son cruciales para los ViTs, particularmente cuando se entrena con conjuntos de datos más pequeños, ya que

aumentan eficazmente el tamaño "aparente" del conjunto de datos. El uso juicioso de AugReg puede producir ganancias de precisión similares a las de aumentar el tamaño del conjunto de datos en un orden de magnitud. El aprendizaje por transferencia, al cargar coeficientes pre-entrenados, es una práctica común para reducir el requisito de grandes conjuntos de datos y el tiempo de entrenamiento para tareas posteriores. La sinergia entre el pre-entrenamiento masivo y la sofisticada aumentación de datos para los ViTs revela una "paradoja de la eficiencia de datos" para la detección OOD en ViTs. Aunque son inherentemente hambrientos de datos, estas técnicas les permiten aprender representaciones de características altamente generalizadas y robustas que son más discriminativas para las tareas OOD, incluso cuando se ajustan finamente en conjuntos de datos ID más pequeños y específicos. Esto implica que la inversión computacional inicial en el pre-entrenamiento se amortiza en muchas tareas posteriores, lo que los convierte en una opción sólida a pesar del costo inicial. La calidad y diversidad de las representaciones aprendidas de este pre-entrenamiento (mejoradas por AugReg) hacen que los ViTs sean excepcionalmente eficientes en la *transferencia* de este conocimiento a la detección OOD en nuevos conjuntos de datos más pequeños. El pre-entrenamiento permite al ViT aprender un "modelo del mundo" de características visuales altamente general y robusto. Cuando se ajusta finamente, esta base robusta le permite discernir desviaciones sutiles de la distribución ID de manera más efectiva, incluso con datos ID-específicos limitados.

Consideraciones Arquitectónicas para la Generalización OOD en ViTs

Los diseños de arquitectura de ViT afectan significativamente la generalización OOD. Los estudios demuestran que el aumento de las dimensiones de incrustación generalmente mejora el rendimiento OOD. Los hiperparámetros como la tasa de aprendizaje y la decadencia de peso son cruciales para la efectividad de la detección OOD. Los modelos ajustados finamente con tasas de aprendizaje pequeñas y una mayor decadencia de peso tienden a ofrecer mejores capacidades de detección, especialmente con la distancia de Mahalanobis. Esto sugiere que las estrategias de regularización que preservan las representaciones de características aprendidas son beneficiosas para OOD.

3. El Poder del Aprendizaje por Ensemble en la Detección OOD

Fundamentos Teóricos de la Diversidad de Ensemble para un Rendimiento OOD Mejorado

El ensemble de modelos es un método en auge para expandir el campo de representación de características, aprovechando la diversidad esperada del modelo para impulsar el rendimiento de la detección OOD. Sin embargo, los ensembles profundos ingenuos (por ejemplo, a través de diferentes inicializaciones) pueden exhibir una diversidad insuficiente

en la representación de características, lo que lleva a un rendimiento consistente con un solo modelo de tamaño equivalente. Esto subraya que la *diversidad* entre los miembros del ensemble es clave, no solo el número de modelos.

La diversidad de características es importante en los ensembles. El Ensemble de Multi-Comprensión, logrado mediante la introducción de múltiples criterios de entrenamiento o tareas de supervisión distintas, puede aumentar las barreras de pérdida entre los modelos, lo que lleva a representaciones de características de la penúltima capa más diversas y, por lo tanto, a una detección OOD más potente. La distinción crítica entre ensembles "ingenuos" y "diversos" revela que la simple agregación de modelos es insuficiente para un rendimiento OOD óptimo. Las verdaderas ganancias provienen de modelos que aprenden *diferentes perspectivas o vistas de características* de los datos. Esta observación sugiere que los procedimientos de entrenamiento estándar (incluso con diferentes semillas aleatorias) a menudo llevan a que los modelos converjan a "modos" muy similares en el paisaje de pérdida, produciendo representaciones de características altamente correlacionadas. Para la detección OOD, que se basa en la identificación de desviaciones, los modelos correlacionados probablemente cometerán errores similares. Por lo tanto, el verdadero poder de los ensembles para OOD reside en forzar a los modelos a aprender representaciones *complementarias u ortogonales*, de modo que cuando un modelo es incierto o erróneo sobre una muestra OOD, otro podría ser confiado y correcto. Esto exige técnicas explícitas que promuevan la diversidad, como objetivos de entrenamiento variados o arquitecturas distintas, para asegurar que el ensemble cubra colectivamente un rango más amplio de posibles patrones OOD.

Técnicas Comunes de Ensemble y su Relevancia para la Detección OOD

- **Ensembles Profundos:** Entrenar múltiples redes neuronales de forma independiente a partir de diferentes inicializaciones aleatorias y promediar sus predicciones. Aunque simple, su diversidad puede ser limitada. Sin embargo, pueden generar advertencias a través de una mayor incertidumbre.
- **Ensembles de Instantáneas (Snapshot Ensembles):** Entrenar una única red con un programa de tasa de aprendizaje cíclica, guardando los parámetros del modelo en diferentes mínimos locales durante el entrenamiento. Esto permite adquirir múltiples miembros del ensemble a partir de una única ejecución de entrenamiento, con diversidad y precisión variables según el punto de control.
- **Ensemble por Lotes (Batch Ensemble):** Una técnica de ensemble eficiente que entrena múltiples modelos simultáneamente dentro de un único lote, reduciendo el tiempo de entrenamiento en comparación con los ensembles profundos.

- **Ensemble Multi-Entrada Multi-Salida (MIMO Ensemble):** Otro método de ensemble eficiente que procesa múltiples entradas y produce múltiples salidas dentro de un único modelo.
- **Ensembles a Nivel de Características:** Combinar las representaciones de características de diferentes modelos, lo que se ha demostrado factible para la detección OOD.
- **Ensembles de Promedio Ponderado/Simple:** Combinar predicciones (por ejemplo, logits o probabilidades) de múltiples modelos, a menudo utilizando votación o promediado. La ponderación óptima puede lograrse mediante algoritmos genéticos.
- **Ensembles Profundos Credibles (CreDEs):** Un método novedoso que combina la inferencia creíble y el ensemble para predecir límites de probabilidad inferiores y superiores para cada clase, proporcionando una estimación mejorada de la incertidumbre epistémica y la detección OOD.

La evolución de las técnicas de ensemble, desde los simples ensembles profundos hasta métodos más sofisticados como los ensembles de instantáneas, por lotes, MIMO y de multi-comprensión, refleja una comprensión creciente de que la eficiencia y la *diversidad ingenierizada* son primordiales. Esto sugiere una tendencia hacia el desarrollo de ensembles que no solo sean efectivos, sino también computacionalmente prácticos para el despliegue en el mundo real, yendo más allá del enfoque de fuerza bruta de entrenar muchos modelos independientes. El desarrollo de métodos de ensemble eficientes aborda directamente las limitaciones prácticas de los ensembles profundos tradicionales, que incurren en costos computacionales y de memoria significativos en tiempo de prueba. Esto indica un movimiento de las ganancias de rendimiento puramente teóricas a soluciones *desplegables*. El énfasis en la "calidad de la diversidad" y la "multi-comprensión" sugiere además que los investigadores están buscando activamente formas de *diseñar* una mejor diversidad, en lugar de depender solo del azar. Esto refleja un área de investigación madura donde el enfoque está en optimizar el equilibrio entre el rendimiento, la cuantificación de la incertidumbre y la sobrecarga computacional, haciendo que los ensembles sean más viables para los sistemas de IA del mundo real.

Mecanismos por los cuales los Ensembles Mejoran la Detección OOD

Los ensembles pueden reducir los errores de predicción en entornos OOD al utilizar un conjunto más diverso de "características espurias". Esto desafía la sabiduría convencional de centrarse únicamente en características invariantes, lo que sugiere que la incorporación de un gran número de características espurias diversas puede debilitar sus

contribuciones individuales, lo que lleva a un rendimiento de generalización OOD mejorado en general.

4. Logro del 98.11% de AUROC en CIFAR-100: Un Logro de Vanguardia

Rendimiento de Vanguardia en la Detección OOD

Un hito significativo en la detección de Out-of-Distribution (OOD) con Vision Transformers (ViTs) es el logro de un AUROC del 98.11% en la tarea CIFAR-100 (distribución en-distribución) versus CIFAR-10 (distribución fuera de distribución). Este resultado fue obtenido por un ensemble de ViT, utilizando la distancia de Mahalanobis como método de puntuación OOD.

Este rendimiento representa una mejora sustancial con respecto al estado del arte anterior para la detección OOD cercana en este benchmark, que se situaba en un AUROC del 85%. La capacidad de los ViTs, especialmente cuando se utilizan en configuraciones de ensemble, para superar drásticamente los métodos previos resalta su poder para discernir entre clases semánticamente similares pero fuera de la distribución esperada.

La siguiente tabla compara el rendimiento de AUROC (Mahalanobis) para diferentes configuraciones de ViT en la tarea CIFAR-100 vs. CIFAR-10:

Modelo / Configuración	AUROC (Mahalanobis)
ViT-B_16	95.53%
R50+ViT-B_16	96.23%
ViT-L_16	97.98%
ViT Ensemble	98.11%
SOTA Previo (Zhang et al., 2020)	85%
CLIP (Zero-shot)	94.68%
R50+ViT-B_16 (1 imagen OOD por clase)	98.70%
R50+ViT-B_16 (10 imágenes OOD por clase)	99.46%

Export to Sheets

Datos extraídos de.

Como se observa en la tabla, el ensemble de ViT no solo supera significativamente el estado del arte anterior, sino que también mejora el rendimiento de modelos ViT individuales más grandes, como el ViT-L_16. Aunque algunas configuraciones de exposición a valores atípicos de pocas tomas (few-shot outlier exposure) pueden lograr resultados ligeramente superiores con datos OOD adicionales, el rendimiento del ensemble de ViT sin esa exposición explícita sigue siendo notablemente alto y establece un nuevo punto de referencia.

El Papel de la Distancia de Mahalanobis en la Detección OOD

La distancia de Mahalanobis es un método de detección OOD basado en características que mide la distancia de la característica de una muestra con respecto al vector de características medias de las clases conocidas, ajustada por la covarianza de los datos. Este método es particularmente eficaz porque tiene en cuenta la correlación de los datos, lo que lo hace robusto para identificar valores atípicos en distribuciones multidimensionales.

En el contexto de los ViTs, la distancia de Mahalanobis aprovecha las representaciones de características de alta calidad aprendidas por estos modelos. Las visualizaciones de la puntuación OOD de Mahalanobis demuestran que, con una mayor exposición a valores atípicos OOD, los contornos de probabilidad OOD de Mahalanobis se alinean mejor con las clases subyacentes, lo que indica su capacidad para definir límites de decisión claros entre datos ID y OOD. La combinación de las potentes capacidades de extracción de características globales de los ViTs con la sensibilidad estadística de la distancia de Mahalanobis ha demostrado ser una fórmula exitosa para lograr un rendimiento superior en tareas de detección OOD, especialmente en escenarios "casi OOD" donde la distinción es sutil.

Contribución del Ensemble

Aunque la metodología exacta para la formación del ensemble que logró el 98.11% de AUROC no se detalla explícitamente en el documento principal, se afirma que los modelos ViT más grandes, como el ViT-L_16, y los ensembles de ViT, mejoran aún más la detección OOD. Esto sugiere que la combinación de múltiples modelos ViT, presumiblemente a través de técnicas de promediado de predicciones o características, permite una evaluación más robusta y una reducción de la incertidumbre, lo que lleva a una mayor capacidad de discriminación entre distribuciones ID y OOD. La capacidad de los ensembles para aprovechar la diversidad de los modelos y mitigar los errores individuales es un factor clave en la mejora del rendimiento general, lo que se refleja en este resultado de vanguardia.

5. Desafíos y Avances Recientes en la Detección OOD con ViTs

Desafíos Actuales y Limitaciones de los ViTs en la Detección OOD

A pesar de los avances, la detección OOD con transformadores aún enfrenta desafíos significativos. En general, el rendimiento de detección OOD de los transformadores sigue siendo insuficiente para su despliegue en aplicaciones críticas para la seguridad. Esto puede atribuirse a que los transformadores suelen tener más parámetros que las CNNs, lo que exige más datos para su entrenamiento.

Un problema recurrente es la tendencia de los modelos a mostrar una confianza excesiva al clasificar muestras de distribuciones semánticamente diferentes, lo que lleva a predicciones inapropiadas. Además, los modelos pueden tener dificultades para distinguir entre muestras ID de "clases de cola" (menos frecuentes en el conjunto de datos) y muestras OOD.

Desde una perspectiva arquitectónica, aunque los ViTs son eficaces para capturar dependencias de largo alcance, a menudo descuidan la extracción de características locales, ya que los parches 2D se proyectan en vectores mediante una capa lineal simple. Otra observación importante es que la precisión ID (en distribución) a menudo es un indicador deficiente de la precisión OOD, lo que subraya el riesgo de optimizar las arquitecturas de ViT únicamente para el rendimiento ID. Incluso los métodos de búsqueda de arquitectura neuronal (NAS) sin entrenamiento existentes son en gran medida ineficaces para predecir la precisión OOD, a pesar de su eficacia para predecir la precisión ID. Esto indica que la optimización para un dominio no garantiza el rendimiento en el otro.

Avances Recientes (2022-2025)

La investigación en detección OOD con ViTs ha visto una explosión de innovación en los últimos años, abordando muchas de las limitaciones existentes:

- **Enfoques Multi-modales (basados en CLIP):** Los avances recientes en IA, especialmente los modelos de lenguaje visual (VLMs) como CLIP, han revolucionado la detección OOD al pasar de los detectores de imagen unimodales tradicionales a los detectores de imagen-texto multimodales. Métodos como Maximum Concept Matching (MCM) y NegLabel aprovechan las representaciones conjuntas visión-lenguaje para la detección OOD de "cero tomas" (zero-shot). Estos enfoques son ventajosos por su generalizabilidad, ser agnósticos a OOD (no requieren información de datos OOD) y no necesitar entrenamiento adicional para tareas posteriores. Caracterizan la incertidumbre OOD por la distancia de las características visuales al prototipo de concepto ID más cercano.

- **Generación de Datos OOD Sintéticos:** Se han propuesto estrategias para generar datos OOD falsos a partir de datos de entrenamiento ID disponibles, como el uso de redes generativas adversarias (GANs) o datos OOD falsos basados en Jigsaw. Esto ayuda a los modelos a ganar conocimiento sobre datos que se caracterizan de manera diferente a los datos ID, mejorando la identificación OOD posterior.
- **Mapas de Calor de Atención:** Un método novedoso aprovecha los mapas de calor de atención visual de un clasificador ViT. Entrena un autoencoder convolucional para reconstruir estos mapas de calor, utilizando el error de reconstrucción como una señal poderosa para la detección OOD. Este enfoque no requiere etiquetas adicionales durante el entrenamiento, lo que garantiza eficiencia.
- **Vision Transformer Aumentado por el Prior (PViT):** PViT es un marco novedoso que cuantifica la divergencia entre los logits de clase predichos y los logits previos obtenidos de modelos pre-entrenados. A diferencia de los métodos OOD de vanguardia existentes, PViT da forma al límite de decisión entre ID y OOD utilizando la confianza de la guía previa propuesta, sin requerir modelado de datos adicional, métodos de generación o modificaciones estructurales.
- **Modelo de Transformador Latente:** Este enfoque utiliza un VQ-GAN para proporcionar una representación latente altamente comprimida del volumen de entrada, y luego un transformador estima la probabilidad de esta representación comprimida para identificar imágenes OOD, tanto cercanas como lejanas.
- **Diversificación de Características Espurias:** Contrariamente a la sabiduría convencional, se ha demostrado que los métodos basados en ensemble pueden reducir los errores de predicción en entornos OOD al utilizar un conjunto más diverso de "características espurias". Esto sugiere que la incorporación de un gran número de características espurias diversas puede mejorar el rendimiento de generalización OOD.
- **Ensembles Profundos Credibles (CreDEs):** Este método combina la inferencia creíble y el ensemble para predecir límites de probabilidad inferiores y superiores para cada clase, lo que resulta en una estimación mejorada de la incertidumbre epistémica y la detección OOD. Los CreDEs demuestran una mayor precisión de prueba, un menor error de calibración esperado y una estimación de la incertidumbre epistémica significativamente mejorada en comparación con los ensembles profundos tradicionales.

6. Conclusiones

El análisis del rendimiento del ensemble de Vision Transformers (ViT) en la detección de Out-of-Distribution (OOD) en CIFAR-100, particularmente el logro de un AUROC del 98.11%, subraya la capacidad transformadora de estas arquitecturas cuando se combinan con estrategias de ensemble. Este resultado no solo establece un nuevo estado del arte en la desafiante tarea de detección OOD cercana (CIFAR-100 vs. CIFAR-10), sino que también valida la eficacia de los ViTs como potentes extractores de características para escenarios del mundo real donde la identificación de datos no vistos es crucial.

La superioridad de los ViTs en la detección OOD se deriva de su capacidad inherente para capturar el contexto global y las dependencias de largo alcance en las imágenes, lo que les permite discernir cambios semánticos sutiles que pueden eludir a las arquitecturas más localizadas como las CNNs. Esta habilidad se ve amplificada por el pre-entrenamiento a gran escala en conjuntos de datos diversos y el uso de técnicas de aumentación de datos sofisticadas. Si bien los ViTs son inherentemente "hambrientos de datos", la inversión computacional inicial en el pre-entrenamiento se traduce en representaciones de características altamente generalizadas y robustas, que son excepcionalmente eficientes para la detección OOD en tareas posteriores, incluso con conjuntos de datos específicos más pequeños.

El papel del aprendizaje por ensemble es fundamental para este rendimiento de vanguardia. La investigación indica que la diversidad de modelos dentro de un ensemble es más importante que la mera cantidad. Los ensembles que fomentan la "multi-comprensión" o las "vistas de características" distintas entre sus miembros pueden superar las limitaciones de los ensembles ingenuos, que a menudo producen modelos correlacionados. La evolución hacia técnicas de ensemble más eficientes y diseñadas para la diversidad (como los ensembles de instantáneas o por lotes) demuestra un enfoque maduro en la investigación, buscando soluciones prácticas y desplegables que equilibren el rendimiento, la cuantificación de la incertidumbre y la eficiencia computacional.

La distancia de Mahalanobis ha demostrado ser una métrica de puntuación OOD particularmente eficaz, aprovechando las ricas representaciones de características de los ViTs para distinguir con precisión entre datos ID y OOD. Su capacidad para considerar la covarianza de los datos la hace robusta en espacios de características de alta dimensión.

A pesar de estos logros, persisten desafíos, como la tendencia de los ViTs a la sobreconfianza en datos OOD y la dificultad de la detección OOD en aplicaciones críticas para la seguridad. Sin embargo, los avances recientes, que incluyen enfoques multimodales basados en CLIP, la generación de datos OOD sintéticos, el aprovechamiento de mapas de calor de atención y el desarrollo de arquitecturas como

PViT y ensembles profundos creíbles, están abriendo nuevas vías para mejorar la robustez y fiabilidad de los sistemas de IA.

En última instancia, el éxito del ensemble de ViT en la detección OOD en CIFAR-100 con un AUROC del 98.11% es un testimonio del potencial de la combinación de arquitecturas de transformadores avanzadas con métodos de ensemble estratégicos. Este campo de investigación es vital para el desarrollo de sistemas de IA seguros, fiables y éticos, capaces de operar con confianza en la complejidad e imprevisibilidad del mundo real.

busca como implementar ViT Ensemble 98.11%, dame código

El estudio que menciona el AUROC del 98.11% para el ensemble de Vision Transformers (ViT) en la detección de Out-of-Distribution (OOD) en CIFAR-100 vs. CIFAR-10 no detalla explícitamente la metodología exacta de cómo se formó el ensemble o cómo se aplicó la detección OOD dentro de ese ensemble para lograr ese resultado específico.

Sin embargo, puedo proporcionarle un esquema conceptual de cómo se podría implementar un sistema de detección OOD basado en un ensemble de ViTs utilizando la distancia de Mahalanobis, que fue el método de puntuación OOD clave para este logro. Este código es una guía general y no la implementación exacta utilizada en el estudio, ya que esos detalles no están disponibles en la investigación.

La idea principal es:

1. **Entrenar (o ajustar) múltiples modelos ViT:** Cada modelo se entrena de forma independiente en los datos dentro de la distribución (ID).
2. **Extraer características:** Utilizar los modelos ViT entrenados como extractores de características.
3. **Calcular parámetros de Mahalanobis:** Para cada clase ID, calcular la media y la matriz de covarianza de las características extraídas de los datos de entrenamiento ID.
4. **Puntuación OOD:** Para una nueva muestra, calcular su distancia de Mahalanobis a cada clase ID. La distancia mínima se utiliza como la puntuación OOD.
5. **Ensemble:** Promediar las puntuaciones OOD de todos los modelos en el ensemble.

Aquí tiene un ejemplo conceptual en Python:

Python

```
import torch
```

```
import torch.nn as nn

from torchvision import transforms, datasets

from torch.utils.data import DataLoader, ConcatDataset

from transformers import ViTForImageClassification, ViTFeatureExtractor

from sklearn.covariance import EmpiricalCovariance

import numpy as np

from tqdm import tqdm


# --- 1. Configuración y Carga de Datos ---

# Asegúrese de tener los datasets CIFAR-100 y CIFAR-10 descargados.

# Puede usar torchvision.datasets para esto.


# Transformaciones para las imágenes

transform_train = transforms.Compose(, std=[0.5, 0.5, 0.5]),

])


transform_test = transforms.Compose(, std=[0.5, 0.5, 0.5]),

])


# Cargar CIFAR-100 (In-Distribution - ID)

cifar100_train = datasets.CIFAR100(root='./data', train=True, download=True,
transform=transform_train)

cifar100_test = datasets.CIFAR100(root='./data', train=False, download=True,
transform=transform_test)


# Cargar CIFAR-10 (Out-of-Distribution - OOD)
```

```
cifar10_test = datasets.CIFAR10(root='./data', train=False, download=True,  
transform=transform_test)
```

```
# DataLoaders
```

```
train_loader_id = DataLoader(cifar100_train, batch_size=64, shuffle=True, num_workers=4)
```

```
test_loader_id = DataLoader(cifar100_test, batch_size=64, shuffle=False, num_workers=4)
```

```
test_loader_ood = DataLoader(cifar10_test, batch_size=64, shuffle=False,  
num_workers=4)
```

```
# Número de clases ID
```

```
num_classes_id = len(cifar100_train.classes)
```

```
# --- 2. Definición del Modelo ViT y Ensemble ---
```

```
# Usaremos ViT-Base como ejemplo. Para ViT-L_16, cambiar 'google/vit-base-patch16-224'  
a 'google/vit-large-patch16-224'
```

```
# y ajustar los recursos computacionales.
```

```
def create_vit_model(num_labels):
```

```
    """Crea un modelo ViT pre-entrenado y lo configura para clasificación."""
```

```
    model = ViTForImageClassification.from_pretrained('google/vit-base-patch16-224',  
num_labels=num_labels)
```

```
    return model
```

```
# Número de modelos en el ensemble
```

```
num_ensemble_members = 3 # Un número pequeño para demostración. El estudio usó un  
ensemble, pero no especificó el tamaño.
```

```

ensemble_models =

for _ in range(num_ensemble_members):
    model = create_vit_model(num_classes_id)

    # Aquí se debería cargar pesos pre-entrenados o ajustar el modelo.

    # Para una demostración completa, cada modelo necesitaría ser entrenado/ajustado.

    # Por simplicidad, usaremos modelos sin ajuste fino extenso aquí.

    # En un escenario real, cada modelo se ajustaría en CIFAR-100.

    ensemble_models.append(model)


device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

for model in ensemble_models:

    model.to(device)

    model.eval() # Poner en modo evaluación para extracción de características


# --- 3. Ajuste Fino (Fine-tuning) de los Modelos ViT (Conceptual) ---

# En un escenario real, cada modelo del ensemble se ajustaría en el dataset ID (CIFAR-100).

# Este es un paso conceptual, ya que el entrenamiento completo está fuera del alcance de un ejemplo de código corto.

# Se necesitaría un bucle de entrenamiento con optimizador, función de pérdida, etc.

# Por ejemplo:

# for model in ensemble_models:

#     optimizer = torch.optim.AdamW(model.parameters(), lr=5e-5)

#     for epoch in range(num_epochs):

#         for batch in train_loader_id:

#             inputs, labels = batch

#             inputs, labels = inputs.to(device), labels.to(device)

```

```

#     outputs = model(inputs, labels=labels)
#     loss = outputs.loss
#     loss.backward()
#     optimizer.step()
#     optimizer.zero_grad()
#     print(f"Modelo ajustado: {model}")

```

--- 4. Extracción de Características y Cálculo de Parámetros de Mahalanobis ---

```
feature_extractor = ViTFeatureExtractor.from_pretrained('google/vit-base-patch16-224')
```

```
def extract_features(model, dataloader):
```

```
    """Extrae las características de la última capa oculta de un modelo ViT."""
```

```
    features_list =
```

```
    labels_list =
```

```
    with torch.no_grad():
```

```
        for batch in tqdm(dataloader, desc="Extrayendo características"):
```

```
            inputs, labels = batch
```

```
            inputs = inputs.to(device)
```

```
            # Acceder a la última capa oculta (penultimate layer)
```

```
            outputs = model(inputs, output_hidden_states=True)
```

```
            # El último hidden state es el de la última capa del transformer
```

```
            # El primer token es el CLS token, que representa la característica global
```

```
            features = outputs.hidden_states[-1][:, 0, :].cpu().numpy()
```

```
            features_list.append(features)
```

```
            labels_list.append(labels.cpu().numpy())
```



```

return np.concatenate(features_list), np.concatenate(labels_list)

print("Extrayendo características de entrenamiento ID para el cálculo de Mahalanobis...")

# Usaremos el primer modelo del ensemble para calcular las medias y covarianzas
# En un enfoque más robusto, se podrían promediar las características de todos los
modelos

# o calcular parámetros de Mahalanobis para cada modelo y luego promediar las
puntuaciones.

id_train_features, id_train_labels = extract_features(ensemble_models, train_loader_id)

# Calcular medias y covarianzas por clase

class_means =
class_covariances =

for i in range(num_classes_id):

    class_features = id_train_features[id_train_labels == i]

    class_means.append(np.mean(class_features, axis=0))

    # Calcular la covarianza empírica. Añadir una pequeña cantidad a la diagonal para
    estabilidad.

    cov = EmpiricalCovariance().fit(class_features).covariance_

    class_covariances.append(cov + np.eye(cov.shape) * 1e-6) # Estabilidad numérica

# --- 5. Función de Puntuación OOD (Distancia de Mahalanobis) ---

def mahalanobis_distance(features, mean, cov_inv):

    """Calcula la distancia de Mahalanobis."""

    diff = features - mean

    return np.sqrt(np.dot(diff, np.dot(cov_inv, diff.T)))

```

```

def calculate_ood_score_mahalanobis(model, image_tensor):
    """Calcula la puntuación OOD de Mahalanobis para una imagen."""
    model.eval()
    with torch.no_grad():
        inputs = image_tensor.unsqueeze(0).to(device) # Añadir dimensión de batch
        outputs = model(inputs, output_hidden_states=True)
        features = outputs.hidden_states[-1][:, 0, :].cpu().numpy().squeeze()

    min_mahalanobis_dist = float('inf')
    for i in range(num_classes_id):
        mean = class_means[i]
        cov_inv = np.linalg.inv(class_covariances[i])
        dist = mahalanobis_distance(features, mean, cov_inv)
        min_mahalanobis_dist = min(min_mahalanobis_dist, dist)
    return min_mahalanobis_dist

```

--- 6. Evaluación del Ensemble para Detección OOD ---

```

def evaluate_ensemble_ood(ensemble_models, dataloader, is_ood_dataset=False):
    """Evalúa el rendimiento OOD del ensemble."""
    ood_scores =
    labels = # 0 para ID, 1 para OOD

    for batch in tqdm(dataloader, desc=f"Evaluando {'OOD' if is_ood_dataset else 'ID'}"):
        images, _ = batch

```

```

ensemble_scores_batch =
for model in ensemble_models:
    # Calcular la puntuación OOD para cada imagen en el batch con cada modelo
    model_scores = [calculate_ood_score_mahalanobis(model, img) for img in images]
    ensemble_scores_batch.append(model_scores)

# Promediar las puntuaciones OOD de los modelos del ensemble
avg_ensemble_scores = np.mean(ensemble_scores_batch, axis=0)
ood_scores.extend(avg_ensemble_scores)
labels.extend([1 if is_ood_dataset else 0] * len(images))

return np.array(ood_scores), np.array(labels)

print("\nEvaluando el rendimiento OOD del ensemble...")

# Obtener puntuaciones para datos ID (CIFAR-100 test)
id_scores, id_labels = evaluate_ensemble_ood(ensemble_models, test_loader_id,
is_ood_dataset=False)

# Obtener puntuaciones para datos OOD (CIFAR-10 test)
ood_scores, ood_labels = evaluate_ensemble_ood(ensemble_models, test_loader_ood,
is_ood_dataset=True)

all_scores = np.concatenate((id_scores, ood_scores))
all_labels = np.concatenate((id_labels, ood_labels))

```

Para calcular el AUROC, necesitamos una librería como scikit-learn

```
from sklearn.metrics import roc_auc_score
```

Un AUROC más alto indica mejor separación entre ID y OOD.

Las etiquetas deben ser 0 para ID y 1 para OOD.

Las puntuaciones deben ser más altas para OOD.

```
auroc = roc_auc_score(all_labels, all_scores)
```

```
print(f"\nAUROC del Ensemble (Mahalanobis): {auroc:.4f}")
```

--- Notas Importantes para una Implementación Real ---

1. Pre-entrenamiento y Ajuste Fino: Los ViTs requieren un pre-entrenamiento a gran escala (ej. ImageNet-21k)

y un ajuste fino cuidadoso en el dataset ID (CIFAR-100) para un rendimiento óptimo.[1, 3, 4, 5, 6, 7, 8, 9, 2]

El código anterior asume modelos pre-entrenados pero no incluye el proceso de ajuste fino completo.

2. Diversidad del Ensemble: La clave de los ensembles es la diversidad entre sus miembros.[10, 11, 12, 13]

Esto se puede lograr con diferentes inicializaciones, diferentes arquitecturas, o técnicas de entrenamiento específicas

(como Snapshot Ensembles [14] o Multi-Comprehension Ensembles [11]).

3. Estabilidad de la Covarianza: Para la distancia de Mahalanobis, la estimación de la matriz de covarianza

puede ser inestable con datos limitados o de alta dimensión. Se pueden usar técnicas de regularización

o estimadores de covarianza más robustos.

4. Hiperparámetros: Los hiperparámetros como la tasa de aprendizaje y la decadencia de peso son cruciales

para la efectividad de la detección OOD con Mahalanobis.[3]

5. Recursos Computacionales: Entrenar y ejecutar ensembles de ViTs, especialmente los grandes (ViT-L_16),

requiere recursos computacionales significativos.

Explicación del Enfoque y Limitaciones:

- **Modelos ViT:** Se utilizan modelos ViTForImageClassification de la librería transformers de Hugging Face, que ya vienen pre-entrenados en grandes conjuntos de datos como ImageNet. Para replicar el rendimiento de vanguardia, estos modelos necesitarían un ajuste fino específico en CIFAR-100.
- **Extracción de Características:** La distancia de Mahalanobis se calcula sobre las características de la última capa oculta (el token ``) del ViT, ya que estas representan una característica global de la imagen.
- **Distancia de Mahalanobis:** Este método mide qué tan lejos está una muestra de las distribuciones de las clases conocidas, ajustando por la correlación de los datos. Una distancia de Mahalanobis más alta indica una mayor probabilidad de que la muestra sea OOD.
- **Ensemble:** El ensemble combina las puntuaciones OOD de múltiples modelos ViT. Aunque el estudio no especifica cómo se construyó el ensemble, una estrategia común es promediar las puntuaciones de confianza o las características de los modelos individuales. La diversidad entre los modelos del ensemble es crucial para mejorar el rendimiento OOD.
- **Limitaciones del Código:** Este código es una demostración conceptual. Una implementación completa requeriría:
 - Un proceso de ajuste fino (fine-tuning) robusto para cada modelo ViT en el conjunto de datos ID (CIFAR-100).
 - Posiblemente, técnicas más avanzadas para la creación del ensemble que fomenten la diversidad de los modelos.
 - Manejo más sofisticado de la estimación de la covarianza para la distancia de Mahalanobis.

Espero que este esquema le sea útil para comprender cómo se podría abordar la implementación de un sistema de detección OOD de alto rendimiento con ensembles de ViTs.

